

Kolektif Öğrenme Proje Raporu

Proje kapsamında 1500 örnekle 30-Yazar veri seti ile 3000 örnekle Cifar-100 veri seti kullanılarak tek örnekle öğrenme gerçekleştirilmiştir. Örneğin tümünün ve parçalanarak eğitilmesinin öğrenmeye olan etkisi değerlendirilmiştir. Yazar veri setiyle metin sınıflandırma işlemi Naive Bayes Sınıflandırıcısı yardımıyla yapılmıştır. Cifar-100 resim veri seti Konvolusyonel Nöron Ağları kullanılarak eğitilmiştir.

Naive Bayes, Bayes koşullu olasılık teoremine dayanan eğitici öğrenme yöntemlerinden biridir. Naive Bayes yönteminin adımları aşağıda sıralanmıştır.

1. Doküman eğitim ve test seti olarak ayrılır.

2. Verileri düzenlemek ve gereksiz bilgileri kaldırmak için verilere ön işlemler uygulanır.

Ön işlemler aşamasında tüm harfler küçük harf yapılır. Sayıların ayrı ayrı ele alınmaması için 'number' kelimesiyle değiştirilir. Noktalama işaretleri temizlenir. Kelimeler arasındaki gereksiz boşluklar kaldırılır. Metindeki gereksiz kelimeler stopwords listesi yardımıyla silinir.

3. Ön işlemden geçirilen eğitim verisinden tekrarsız sözlük oluşturulur. Sözlükte kelime,

J sınıfında kaç kere geçtiği bilgisi bulunur. Bu frekans bilgileri ve toplam sözcük sayısı yardımıyla kelimelerin bulunma olasılıkları hesaplanır.

4. Eşitlik 1'de gösterildiği şekilde j sınıfında her bir kelimenin bulunma ihtimali, koşullu olasılık yardımıyla hesaplanır.

$$P(w_k|v_j) = \frac{-n_k + m}{n_j + |\text{vocabulary}|}$$

m = sabit

n_k = w_k kelimesinin j. sınıfta kaç defa geçtiği

n_j = j. sınıftaki kelime sayısı

|\text{vocabulary}| = sözlükteki tekrarsız kelime sayısı

5. Sınıfların olasılıkları hesaplanır.

6. Test verisi ön işlemden geçirilir.

7. Sözlükte yer alan kelimelerin koşullu olasılık hesaplarına ve sınıf olasılıklarına göre metinlerin her bir sınıfta bulunma olasılığı saptanır. Yüksek olan olasılık metnin ait olduğu sınıfı gösterir.


	Örnek Sayısı					
	1	1 (Parçalı)	2	2 (Parçalı)	5	5 (Parçalı)
Başarı	0.04	0.21	0.04	0.24	0.04	0.29
	0.04	0.17	0.06	0.24	0.04	0.31
	0.04	0.18	0.04	0.22	0.04	0.31
	0.04	0.18	0.04	0.25	0.03	0.31
	0.03	0.21	0.04	0.24	0.04	0.30

Tablo 1: 1,2,5 örnekle eğitilen modellerin ve parçalı örneklerin başarıları (30 Yazar Veriseti)

30-Yazar veri seti her bir yazara ait 50 köşe yazısı içermektedir. 30-Yazar veriseti için her bir köşe yazısı birer örnek olarak ele alınmıştır. Eğitimde 1, 2 ve 5 örnek; testte, kalan 1499, 1498 ve 1495 örnek kullanılmıştır. Bir veya birkaç örnekle yapılan eğitimin başarısı değerlendirilmiştir. Ayrıca, örnekler satır satır ayrılarak, her bir satır ayrı birer örnek olarak eğitilmiş ve benzer şekilde test edilmiştir. Tablo 1’de her bir eğitim örneği modelinde 5 farklı orijinal örnek ele alınmıştır. 5 farklı orijinal eğitim seti ve her birinden elde edilen parçalı eğitim setlerine ait başarı oranları Tablo 1’de gösterilmiştir. Modeli eğitmek için kullanılan ortalama eğitim örneği sayıları Tablo 2’de verilmiştir.

Ortalama Örnek Sayısı					
1	1 (Parçalı)	2	2 (Parçalı)	5	5 (Parçalı)
30	16	60	30	150	70


Tablo 2: Orijinal ve parçalı örnekler kullanılarak elde edilen eğitim seti örnek sayıları.



Tablo 3: Orijinal ve parçalı örneklerin ortalama başarısı.

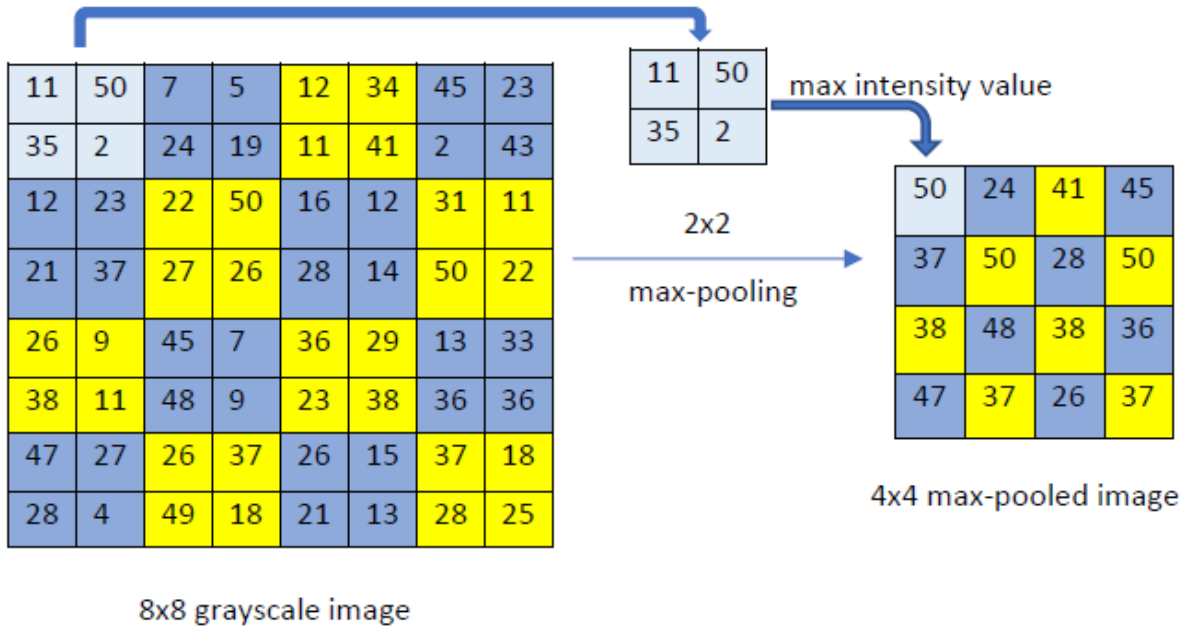
Tablo 1’de verilen az sayıda orijinal ve parçalı örnekle yapılan eğitimlerin başarıları verilmiştir. Tablo 3’te bu verilere ait ortalama başarı değerleri gösterilmiştir. Yazar veri setiyle yapılan eğitimin sonucunda elde edilen sonuçlar parçalı örneklerle yapılan öğrenmenin daha iyi olduğunu göstermektedir. Ayrıca örnek sayısı arttırıldığında parçalı örneklerde başarı hızlı bir şekilde artmaktadır.

Cifar-100 resim veri seti Keras derin öğrenme kütüphanesi kullanılarak Image-Net VGG-16 konvolüsyonel ağı yardımıyla eğitilmiştir. Konvolüsyonel ağların çalışma prensibi Şekil1 ve Şekil 2’de anlatılmıştır.



Şekil 1: Konvolüsyonel Nöral Ağ

Girdi görüntüsü ilk konvolüsyonel katmanda farklı ağırlıklara sahip filtrelerden geçirilerek bias değerleri eklenir. Her bir filtre için bir çıktı görüntüsü elde edilir. Filtreler negatif (kırmızı) ve pozitif (mavi) ağırlıklardan oluşur. Bu filtrelerin her birinin görüntüdeki farklı bir özelliği öne çıkarmak için kullanıldığı düşünülebilir. Örneğin filtrenin biri girdinin yatay yönlü özelliklerini bulurken, bir diğeri girdideki köşe noktası özelliklerini saptayabilir. Çeşitli filtrelerden geçirilen görüntüler bir çeşit aktivasyon fonksiyonu olan ReLU (Rectified Linear Unit) yöntemiyle işlenir. ReLU fonksiyonu $f(x) = \max(0, x)$ şeklinde ifade edilir ve önceki adımda elde edilen değerlerin negatif olanlarını 0'a dönüştürür. ReLU fonksiyonu uygulanan çıktı görüntüler max-pooling yöntemiyle yeniden boyutlandırılmıştır. Bu sayede güçlü özellikleri kaybetmeksizin her bir girdi için yapılacak işlem yükü azaltılmıştır. Genelde pooling olarak adlandırılan örnekleme azaltma yönteminin bir türü olan max-pooling, görüntünün 2x2 boyutlarında gruplanarak, her bir grubun kendi içindeki maksimum renk yoğunluğu değeriyle temsil edilmesidir. Max-pooling yöntemi Şekil 2' de örnekle gösterilmiştir.



Şekil 2. Maximum Pooling

Şekil 2' de 8x8 boyutlarındaki girdi görüntüsü, 2x2 piksellik gruplara ayrılır. Her bir gruptaki maksimum renk değeri kaydedilir. Diğer üç renk değeri silinir. Her bir grup maksimum renk değeriyle temsil edilerek görüntü güçlü özelliklerini kaybetmeksizin 4 kat küçültülmüş olur.

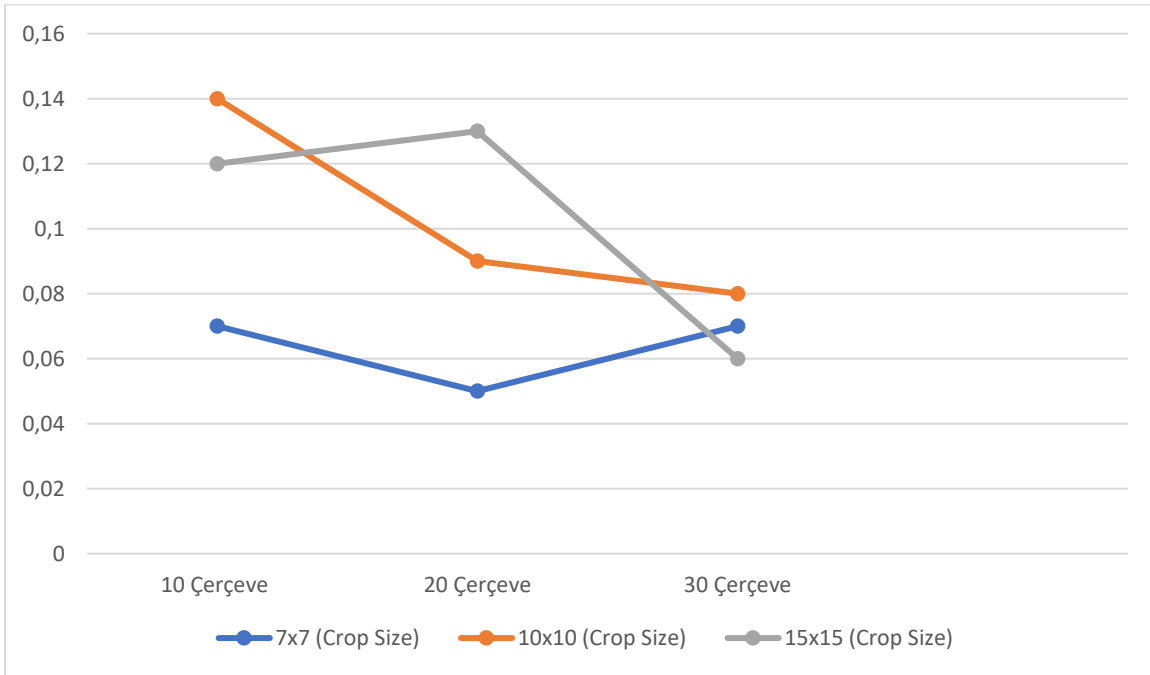
Max-pooling işleminin çıktısı olan 16 görüntü kanalı ikinci konvolüsyonel katmana girdi olarak verilmiştir. İkinci katmanın çıktılarına da birinci katmanda olduğu gibi ReLU ve max-pooling uygulanarak çıktı elde edilmiştir. 36 tane çıktı kanalı birleştirilerek 7x7x36 boyutlarında görüntünün özelliklerini temsil eden vektör oluşturulur ve tam bağlantılı katmana girdi olarak verilir. Tam bağlantılı katman girdileri alır ve sahip olduğu nöron sayısı kadar çıktı verir. Şekil 1’de gösterilen çıktı katmanı da 10 nörona sahip olan tam bağlantılı bir katmandır. Bu katmandaki nöron sayısı sınıf sayısını belirler. Tam bağlantılı katman özellik çıkarmada kullanılan filtre ağırlıklarını değiştirerek (backpropagation) optimum ağırlıkları hesaplar. İkinci tam bağlantılı katman da girdinin hangi sınıfa ait olabileceğini olasılıksal olarak belirler ve etiketini oluşturur.

Cifar-100 veri setinden 30 sınıf belirlenerek, çeşitli “tek örnek” ler eğitim için seçilmiştir. Test seti olarak her bir sınıf için 100 örnek seçilmiştir. Örnekler hem orijinal biçimleriyle hem de rastgele kırılmış olan dxd boyutlarında n tane çerçeve eğitilerek sonuçlar ayrı ayrı değerlendirilmiştir. Seçilen 5 tane örnekle oluşturulan model için test sonuçları Tablo 4’te gösterilmiştir.

	Örnek No				
	1	2	3	4	5
Başarı →	0.18	0.20	0.14	0.12	0.22

Tablo 4. Farklı tek örneklerin model başarısı.

Seçilen 5 orijinal örneğin ortalama başarısı 0.17’dir. Daha sonra birinci örnek 7x7, 10x10 ve 15x15 boyutlarında rastgele kırılarak 10, 20 ve 30 tane resim oluşturulmuştur. Bu örnekler eğitilerek modelin başarısı Tablo 5’te değerlendirilmiştir.



Tablo 5. Farklı kırma boyutları ve farklı kırma sayılarının model başarısına etkisi.

Tablo 5 incelendiğinde en başarılı modelin 10x10 boyutlarında kırılmış 10 tane çerçevenin eğitilmesinden elde edildiği görülmüştür. Ancak tek örneğin tamamıyla yapılan eğitimden elde edilen başarı (0,15) parçalı örneklerin her birinin başarısından daha yüksektir.

Yazar veri setiyle yapılan çalışmada parçalı örneklerin model başarısı daha yüksek olmasına rağmen, Cifar-100 veri setinde tek orijinal örnekle oluşturulan model daha başarılıdır.